



Universidad Autónoma del Carmen
Facultad de Ciencias de la Información
Ing. en Sistemas Computacionales

Aplicación del algoritmo ID3 en los datos de la Flor
Iris
Actividad 2

Integrantes.

Cristóbal Rafael **Lara Páez** (191490)
Ricardo José **Chablé Montero** (180283)

Asignatura. Programación Avanzada
Docente. Jesús Alejandro Flores Hernández

2 de septiembre del 2026

Índice

Adaptación del Dataset y Aplicación de ID3.....	2
1. Cálculo de la Entropía general.....	3
2. Definición del nodo raíz.....	3
3. Definición de las ramas de petalw.....	4
3.1 Rama Chico (Nodo petalw).....	4
3.2 Rama Mediano (Nodo petalw).....	5
3.3 Definición de ramas de petall.....	6
3.3.1 Rama Grande (Nodo petall).....	7
3.4 Rama Grande (Nodo petalw).....	7
3.5 Definición de ramas de petall.....	8
3.5.1 Rama Mediano (Nodo petall).....	9
3.5.2 Rama Grande (Nodo petall).....	10
3.5.3 Reducción de las ramas Mediano y Grande (Nodo petall).....	10
4. Árbol de decisión final.....	11

Adaptación del Dataset y Aplicación de ID3

Debido a que el algoritmo original ID3 fue planeado para procesar valores discretos o categóricos, se tuvo que preprocesar el dataset de la flor Iris para poder aplicar el algoritmo. Se decidió dividir cada uno de los rangos de valores en 3 subrangos equitativos, los datos de cada uno de los atributos de la flor quedaron de la siguiente manera:

- **sepal**
 - **Chico:** < 5.5
 - **Mediano:** >= 5.5, y < 6.7
 - **Grande:** >= 6.7
- **sepalw**
 - **Chico:** < 2.8
 - **Mediano:** >= 2.8, y < 3.6
 - **Grande:** >= 3.6
- **petal**
 - **Chico:** < 3
 - **Mediano:** >= 3, y < 5
 - **Grande:** >= 5
- **petalw**
 - **Chico:** < 0.9
 - **Mediano:** >= 0.9, y < 1.7
 - **Grande:** >= 1.7

Tras este preprocesado, los datos del set quedaron de la siguiente manera:

	A	B	C	D	E
1	sepal	sepalw	petal	petalw	clase
2	Chico	Mediano	Chico	Chico	Iris-setosa
3	Chico	Mediano	Chico	Chico	Iris-setosa
4	Chico	Mediano	Chico	Chico	Iris-setosa
5	Chico	Mediano	Chico	Chico	Iris-setosa
6	Chico	Mediano	Chico	Chico	Iris-setosa
7	Chico	Grande	Chico	Chico	Iris-setosa
8	Chico	Mediano	Chico	Chico	Iris-setosa
9	Chico	Mediano	Chico	Chico	Iris-setosa
10	Chico	Mediano	Chico	Chico	Iris-setosa
11	Chico	Grande	Chico	Chico	Iris-setosa
12	Chico	Mediano	Chico	Chico	Iris-setosa
13	Chico	Mediano	Chico	Chico	Iris-setosa
14	Chico	Mediano	Chico	Chico	Iris-setosa
15	Chico	Mediano	Chico	Chico	Iris-setosa
16	Chico	Mediano	Chico	Chico	Iris-setosa
17	Chico	Mediano	Chico	Chico	Iris-setosa
18	Chico	Mediano	Chico	Chico	Iris-setosa
19	Chico	Mediano	Chico	Chico	Iris-setosa
20	Chico	Mediano	Chico	Chico	Iris-setosa
21	Chico	Mediano	Chico	Chico	Iris-setosa
22	Chico	Grande	Chico	Chico	Iris-setosa
23	Chico	Mediano	Chico	Chico	Iris-setosa
24	Chico	Mediano	Chico	Chico	Iris-setosa
25	Chico	Mediano	Chico	Chico	Iris-setosa

1. Cálculo de la Entropía general

Primero debemos de calcular la entropía general del dataset:

Valores de clase (i)			
Iris-setosa	Iris-versicolor	Iris-virginica	Total de datos
50	50	50	150

$$Entropía(S) = - \sum (p_i) \log_2(p_i)$$

$$Entropía(S) = - \left[\left(\frac{50}{150}\right) \log_2\left(\frac{50}{150}\right) + \left(\frac{50}{150}\right) \log_2\left(\frac{50}{150}\right) + \left(\frac{50}{150}\right) \log_2\left(\frac{50}{150}\right) \right]$$

$$Entropía(S) \approx 1.58496250$$

Debido a que cada clase de Iris tiene 50 elementos, estos tienen una distribución equitativa, por lo que todos los diferentes valores de p_i son iguales.

2. Definición del nodo raíz

Con la entropía general, se debe de obtener la ganancia de cada uno de los subconjuntos de nuestro dataset, para así definir el nodo raíz del árbol de decisión.

Debemos de calcular la entropía de cada uno de atributos que tiene nuestro dataset: **sepal**, **sepalw**, **petal** y **petalw**. Para esto debemos agruparlos en subconjuntos con todos los valores posibles, en nuestro caso: **chico**, **mediano** y **grande**. Y contar cada cuantas entradas tienen dicho valor, ejemplo para el atributo **sepal**:

Subconjuntos del atributo sepal			
Chico	Mediano	Grande	Total de datos
52	70	28	150

Después, es necesario determinar la frecuencia de cada clase de Iris dentro de los subconjuntos definidos, lo cual permitirá calcular la entropía específica para cada categoría de los atributos, se muestra un ejemplo con la frecuencia de las clases del subconjunto **Chico**:

Clases Subconjunto		Chico
Iris-setosa	Iris-versicolor	Iris-virginica
45	6	1

Con esto, ya podemos calcular la Entropía de cada subconjunto de los atributos, se continúa con el ejemplo del cálculo de la entropía del subconjunto **Chico** del atributo **sepal** (se usa la misma fórmula desarrollada al inicio):

Entropía Subconjunto 'Chico'			
Iris-setosa	Iris-versicolor	Iris-virginica	Entropía
0.1805076535	0.3594781405	0.1096238407	0.6496096347

Con todas las entropías de cada subconjunto del atributo, se debe de calcular la entropía promedio ponderada de cada subconjunto, usando la siguiente fórmula:

$$Entropía \text{ Promedio Ponderada} = \left(\frac{|S_v|}{|S|} \right) \cdot Entropía(S_v)$$

En esta expresión, S_v representa la frecuencia de ejemplares que pertenecen a una categoría específica (*Iris-setosa*, *Iris-versicolor* o *Iris-virginica*) dentro de los subgrupos establecidos.

Sumatoria Porcentaje * Entropía		
Chico	Mediano	Grande
0.2251980067	0.5975797509	0.1399244480

Por último, para obtener la ganancia del atributo, debemos de restarle a la Entropía general la sumatoria de las Entropías Promedio Ponderadas del atributo, con la siguiente fórmula:

$$Ganancia(S, A) = Entropía(S) - \sum Entropía \text{ Promedio Ponderada}(S_v)$$

Ganancia del atributo sepal	0.62226030
------------------------------------	------------

Ahora debemos de repetir estos pasos en cada uno de los atributos del set de datos.

$$Ganancia(S, sepal) = 0.62226030$$

$$Ganancia(S, sepalw) = 0.22358373$$


$$Ganancia(S, petal) = 1.32466378$$

$$Ganancia(S, petalw) = 1.36936906$$

Con esto, obtenemos que el nodo raíz de nuestro árbol de decisión será el atributo **petalw**: puesto que es el atributo que tiene la mayor ganancia de los 4.

3. Definición de las ramas de **petalw**

Debido a que **petalw** es el nodo raíz del árbol, cada uno de sus valores posibles se vuelve una rama que sale de este nodo. Por lo que el árbol nos querría de la siguiente manera:




3.1 Rama **Chico** (Nodo **petalw**)

Tras esto debemos de analizar todos los valores posibles de las clases para cada valor de **petalw**. En este caso, observamos que cuando **petalw** es **Chico**, la flor será de tipo Setosa.

Clases Subconjunto		Chico
Iris-setosa	Iris-versicolor	Iris-virginica
50	0	0

Por lo que se pone el resultado como nodo hoja de la rama **Chico**. Por lo que el árbol de decisión quedará de la siguiente manera.



3.2 Rama **Mediano** (Nodo **petalw**)

Continuamos analizando las ramas del atributo **petalw**, en este caso, analizaremos la rama **Mediano**. Primero, debemos calcular la ganancia de cada uno de los atributos restantes del set (**sepal**, **sepalw** y **petal**). Debemos de repetir los pasos que seguimos para calcular las ganancias de cada uno de los atributos originales, solamente teniendo en cuenta las siguientes consideraciones:

- Sustituimos el valor de la Entropía general por la entropía correspondiente al nodo raíz; para este análisis el valor es:

$$Entropía(petalw = Mediano|S) \approx 0.39124356$$
- Se considerarán exclusivamente los registros que presenten la categoría **Mediano** dentro del atributo **petalw**.

Tras estas consideraciones, realizamos los mismos pasos que se siguieron para calcular las ganancias de cada uno de los atributos con base a sus subconjuntos:

1. Agrupar en subconjuntos con todos los valores posibles (**chico**, **mediano** y **grande**)
2. Determinar la frecuencia de cada clase de Iris dentro de los subconjuntos definidos.
3. Calcular la entropía de cada subconjunto con base a los valores de las clases de Iris.
4. Calcular las Entropías Promedio Ponderadas de cada uno de los subconjuntos.
5. Restar a la entropía del nodo raíz la sumatoria de las entropías promedio ponderadas para obtener la ganancia.


Tras repetir los mismos pasos del algoritmo en la rama mediano, obtendremos las siguientes ganancias por atributo:

$$Ganancia(petalw = Mediano, sepal) = 0.02061671$$

$$Ganancia(petalw = Mediano, sepalw) = 0.00080615$$

$$Ganancia(petalw = Mediano, petal) = 0.32182740$$

Al analizar las diferentes ganancias, observamos que la ganancia más alta es la del atributo **petal**, por lo que se selecciona como siguiente nodo, dejando el árbol de decisión de la siguiente manera:



3.3 Definición de ramas de *petall*

Analizamos las distribuciones de clases del atributo ***petall***, y observamos que:

Clases Subconjunto		Chico
Iris-setosa	Iris-versicolor	Iris-virginica
0	0	0

No se presentan ejemplares de Iris con los valores ***Mediano*** para el atributo ***petalw*** y ***Chico*** en el caso de ***petall***.


Clases Subconjunto		Mediano
Iris-setosa	Iris-versicolor	Iris-virginica
0	47	0

Cuando ***petalw*** es ***Mediano*** y ***petall*** es ***Mediano***: la flor será *Iris-versicolor*.

Clases Subconjunto		Grande
Iris-setosa	Iris-versicolor	Iris-virginica
0	1	4

Cuando ***petalw*** es ***Mediano*** y ***petall*** es ***Grande***: la flor muy probablemente será *Iris-virginica*.

Con esto podemos definir las ramas del nodo ***petall***, así como el nodo hoja de la rama ***Mediano*** de la misma. También se puede inferir cuál será el nodo hoja de la rama ***Grande***. Por lo que el árbol nos quedaría de la siguiente manera:



3.3.1 Rama Grande (Nodo petalw)


Como se comentó en las observaciones, se puede ver que cuando **petalw** es **Mediano** y **petall** es **Mediano**. Podemos seguir aplicando las fórmulas de ID3 para obtener las ganancias de los atributos faltantes (**sepall** y **sepalw**). Aplicando las fórmulas a los dos atributos restantes, obtendremos las siguientes ganancias:

$$\text{Ganancia}(\text{petalw} = \text{Mediano} | \text{petall} = \text{Grande}, \text{sepall}) = 0.07290560$$

$$\text{Ganancia}(\text{petalw} = \text{Mediano} | \text{petall} = \text{Grande}, \text{sepalw}) = 0.17095059$$

Podríamos seguir aplicando los criterios de análisis y seguir desarrollando el árbol, pero si recordamos, la muestra actual de los datos a evaluar es de apenas 5 muestras, por lo que estaríamos sobreajustando nuestro árbol de decisión: debido a que crearíamos reglas para casos atípicos, por lo que es recomendable detener el algoritmo para evitar el sobreajuste.

Cómo detuvimos el desarrollo de esta rama, se debe de definir el nodo hoja de nuestra rama: al analizar los datos de nuestra rama: podemos que cuando **petall** sea **Grande** será de tipo **Iris-virginica** el 80% de las veces, por lo que podemos decir con cierta seguridad que cuando se cumpla esta condición la flor será de tipo **Iris-virginica**; con esto podemos actualizar nuestro árbol de decisión:



3.4 Rama Grande (Nodo petalw)


Regresamos a evaluar la última rama del nodo raíz. Repetimos el proceso de calcular las ganancias de los atributos restantes (**sepall**, **sepalw** y **petall**), y siguiendo las mismas consideraciones cuando se evaluó la rama **Mediano**, podemos obtener las ganancias de cada uno de los atributos:

$$\text{Ganancia}(\text{petalw} = \text{Grande}, \text{sepall}) = 0.00142116$$

$$\text{Ganancia}(\text{petalw} = \text{Grande}, \text{sepalw}) = 0.01772472$$

$$\text{Ganancia}(\text{petalw} = \text{Grande}, \text{petall}) = 0.02229442$$

Si observamos, podemos ver que en esta rama también contamos con una ganancia mínima, pero a diferencia del caso anterior del nodo **petalw** en la rama **Mediano** de **petalw**, aquí se cuenta con suficiente volumen de datos para poder respaldar la creación de una regla par dividir los casos posibles; teniendo un total de 48 casos totales, por lo que se decide continuar con el algoritmo, usando el atributo **petalw** como el siguiente nodo. Terminando con el árbol de la siguiente manera:



3.5 Definición de ramas de **petalw**

Analizamos las distribuciones de clases del atributo **petalw**, y observamos que:

Clases Subconjunto		Chico
Iris-setosa	Iris-versicolor	Iris-virginica
0	0	0

No se presentan ejemplares de Iris con los valores **Grande** para el atributo **petalw** y **Chico** en el caso de **petalw**.


Clases Subconjunto		Mediano
Iris-setosa	Iris-versicolor	Iris-virginica
0	1	6

Cuando **petalw** es **Grande** y **petalw** es **Mediano**: la flor muy probablemente será Iris-virginica.

Clases Subconjunto		Grande
Iris-setosa	Iris-versicolor	Iris-virginica
0	1	40

Cuando **petalw** es **Grande** y **petalw** es **Grande**: la flor muy probablemente será Iris-virginica.

Con esto podemos definir las ramas del nodo **petall**. También se puede inferir cuáles serán los nodos hojas de la rama **Mediano** y **Grande**. Por lo que el árbol nos quedaría de la siguiente manera:



3.5.1 Rama Mediano (Nodo petall)

Podemos seguir calculando las ganancias, pero volveríamos al problema de tener ganancias muy bajas, en este caso:


$$\text{Ganancia}(\text{petalw} = \text{Grande} | \text{petall} = \text{Mediano}, \text{sepall}) = 0.03451070$$

$$\text{Ganancia}(\text{petalw} = \text{Grande} | \text{petall} = \text{Mediano}, \text{sepalw}) = 0.07600985$$

Entonces podemos optar por volver a realizar un análisis de los datos para determinar un nodo hoja, si observamos, vemos que cuando **petall** es **Mediano** la flor será de tipo **Iris-virginica** el 85.7% de las veces, por lo que podemos decir con certeza que cuando se cumpla la condición, la flor será de tipo **Iris-virginica**.

Subconjuntos del atributo petall			
Iris-setosa	Iris-versicolor	Iris-virginica	Total de datos
0	1	6	7

Con esta observación, el árbol quedaría de la siguiente manera:



3.5.2 Rama Grande (Nodo petall)

Podemos seguir calculando las ganancias, pero volveríamos al problema de tener ganancias muy bajas, en este caso:


$$\text{Ganancia}(\text{petalw} = \text{Grande} | \text{petall} = \text{Grande}, \text{sepal}) = 0.02228485$$

$$\text{Ganancia}(\text{petalw} = \text{Grande} | \text{petall} = \text{Grande}, \text{sepalw}) = 0.00997904$$

Entonces podemos optar por volver a realizar un análisis de los datos para determinar un nodo hoja, si observamos, vemos que cuando **petall** es **Grande** la flor será de tipo **Iris-virginica** el 97.5% de las veces, por lo que podemos decir con certeza que cuando se cumpla la condición, la flor será de tipo **Iris-virginica**.

Subconjuntos del atributo petall			
Iris-setosa	Iris-versicolor	Iris-virginica	Total de datos
0	1	40	41

Con esta observación, el árbol quedaría de la siguiente manera:



3.5.3 Reducción de las ramas Mediano y Grande (Nodo petall)

Si observamos el árbol final, nos damos cuenta de que las dos ramas de petall llevan al mismo resultado, por lo que a pesar de que el nodo contaba con cierta ganancia para dividir la lista, el resultado final dio lo mismo en ambos casos. Podemos reducir el árbol eliminando las dos hojas del nodo **petall**, así como también el propio nodo **petall**, y sustituirlo con la clase **Iris-virginica** como nuevo nodo hoja de la rama **Grande** de la raíz **petalw**.

Dejando el árbol de decisión de la siguiente manera (próxima página):

4. Árbol de decisión final

