

UNIVERSIDAD AUTÓNOMA DEL CARMEN
FACULTAD DE CIENCIAS DE LA INFORMACIÓN
LICENCIATURA EN INGENIERÍA EN SISTEMAS
COMPUTACIONALES



Reporte de la aplicación del algoritmo J48 a los datos iris en weka

Elaborado por:

Ricardo José Chablé Montero

Cristóbal Rafael Lara Páez

Materia: Programación Avanzada

Docente: Jesus Alejandro Flores Hernandez

Fecha: 02/Septiembre/2026

Índice

1. Introducción.....	3
2. Configuración utilizada.....	3
3. Árbol de decisión generado.....	3
3.1 Estructura textual del árbol (salida de Weka).....	3
3.2 Tamaño del árbol.....	3
3.3 Interpretación del árbol.....	4
4. Resultados de la validación cruzada.....	5
4.1 Resumen general.....	5
4.2 Exactitud detallada por clase.....	6
4.3 Matriz de confusión.....	6
5. Discusión de hallazgos.....	7
6. Conclusiones.....	7

1. Introducción

El presente reporte documenta los hallazgos obtenidos tras aplicar el algoritmo J48 (implementación de Weka basada en el algoritmo C4.5, sucesor de ID3) al conjunto de datos Iris, utilizando el software Weka Explorer. El objetivo es construir un árbol de decisión que permita clasificar una flor en una de tres especies (Iris-setosa, Iris-versicolor, Iris-virginica) a partir de cuatro atributos numéricos: largo y ancho de sépalo, y largo y ancho de pétalo.

2. Configuración utilizada

- Clasificador: J48 -C 0.25 -M 2
- -C 0.25: factor de confianza usado para la poda del árbol (a menor valor, mayor poda).
- -M 2: número mínimo de instancias por hoja.
- Modo de evaluación: Validación cruzada estratificada (Stratified cross-validation) con 10 particiones (folds).
- Conjunto de datos: iris.arff, 150 instancias, 3 clases balanceadas (50 instancias por clase).
- Atributo clase (target): class (especie de la flor).

3. Árbol de decisión generado

El árbol construido por J48 utiliza únicamente dos de los cuatro atributos disponibles: petalwidth (ancho de pétalo) y petallength (largo de pétalo). Los atributos de sépalo (sepalwidth, sepalwidth) no fueron utilizados por el algoritmo, lo cual indica que el ancho y largo del pétalo son, por sí solos, suficientes para separar con alta precisión las tres especies.

3.1 Estructura textual del árbol (salida de Weka)

```
petalwidth <= 0.6: Iris-setosa (50.0)
petalwidth > 0.6
|  petalwidth <= 1.7|
|  |  petallength <= 4.9: Iris-versicolor (48.0/1.0)
|  |  petallength > 4.9
|  |  |  petalwidth <= 1.5: Iris-virginica (3.0)
|  |  |  petalwidth > 1.5: Iris-versicolor (3.0/1.0)
|  petalwidth > 1.7: Iris-virginica (46.0/1.0)
```

3.2 Tamaño del árbol

- Número de hojas: 5
- Tamaño total del árbol (nodos): 9
- Tiempo de construcción del modelo: 0.01 segundos

A continuación se muestra la visualización gráfica generada por Weka (Tree Visualizer), donde se aprecian las cuatro reglas de decisión completas, incluyendo la primera división por $\text{petalwidth} \leq 0.6$:




Figura 1. Árbol de decisión J48 generado en Weka.

3.3 Interpretación del árbol

1. Si $\text{petalwidth} \leq 0.6 \rightarrow$ la flor se clasifica como Iris-setosa (50 casos, sin errores). Esta primera regla por sí sola separa perfectamente a setosa del resto de las especies.
2. Si $\text{petalwidth} > 0.6$ y $\text{petalwidth} \leq 1.7$:
 - Si $\text{petallength} \leq 4.9 \rightarrow$ Iris-versicolor (48 casos, 1 mal clasificado).
 - Si $\text{petallength} > 4.9$ y $\text{petalwidth} \leq 1.5 \rightarrow$ Iris-virginica (3 casos).
 - Si $\text{petallength} > 4.9$ y $\text{petalwidth} > 1.5 \rightarrow$ Iris-versicolor (3 casos, 1 mal clasificado).
3. Si $\text{petalwidth} > 1.7 \rightarrow$ Iris-virginica (46 casos, 1 mal clasificado).

Esto confirma un hallazgo bien conocido sobre el dataset Iris: el ancho del pétalo es el atributo más discriminante, seguido del largo del pétalo, mientras que las medidas del sépalo aportan poca o ninguna información adicional para separar las especies.

4. Resultados de la validación cruzada

La salida completa del clasificador, tal como fue generada por Weka, se muestra a continuación:




Figura 2. Salida del clasificador J48 en Weka Explorer.

4.1 Resumen general

Métrica	Valor
Instancias correctamente clasificadas	144 (96 %)
Instancias incorrectamente clasificadas	6 (4 %)
Estadístico Kappa	0.94
Error absoluto medio	0.035
Raíz del error cuadrático medio	0.1586
Error absoluto relativo	7.8705 %
Raíz del error cuadrático relativo	33.6353 %
Total de instancias	150

El modelo alcanza una exactitud del 96 %, con un coeficiente Kappa de 0.94, lo cual indica un grado de concordancia “casi perfecto” entre las predicciones del modelo y las clases reales.

4.2 Exactitud detallada por clase

Clase	TP Rate	FP Rate	Precisión	Recall	F-Measure	ROC Area
Iris-setosa	0.980	0.000	1.000	0.980	0.990	0.990
Iris-versicolor	0.940	0.030	0.940	0.940	0.940	0.952
Iris-virginica	0.960	0.030	0.941	0.960	0.950	0.961
Promedio ponderado	0.960	0.020	0.960	0.960	0.960	0.968

Observaciones:

- Iris-setosa obtiene una precisión perfecta (1.000) y una tasa de falsos positivos de 0.000: el modelo nunca confunde otra especie con setosa, lo cual es consistente con que esta clase se separa completamente en la primera división del árbol ($\text{petalwidth} \leq 0.6$).
- Iris-versicolor e Iris-virginica presentan un desempeño ligeramente menor (F-Measure de 0.940 y 0.950 respectivamente), ya que son las dos especies que se confunden entre sí en los casos límite del árbol (por ejemplo, cuando petallength está cerca de 4.9 o petalwidth cerca de 1.5-1.7).

4.3 Matriz de confusión

```
=== Confusion Matrix ===  
  
  a  b  c  <-- classified as  
49  1  0 |  a = Iris-setosa  
 0 47  3 |  b = Iris-versicolor  
 0  2 48 |  c = Iris-virginica
```

Lectura de la matriz:

- Iris-setosa (fila a): de 50 instancias reales, 49 fueron clasificadas correctamente y solo 1 fue confundida con Iris-versicolor.
- Iris-versicolor (fila b): de 50 instancias reales, 47 fueron clasificadas correctamente y 3 fueron confundidas con Iris-virginica.
- Iris-virginica (fila c): de 50 instancias reales, 48 fueron clasificadas correctamente y 2 fueron confundidas con Iris-versicolor.

En total, los 6 errores de clasificación ocurren exclusivamente entre Iris-versicolor e Iris-virginica; ninguna instancia de Iris-setosa se confunde con las otras dos especies, y viceversa. Esto es coherente con el hecho biológico y estadístico bien documentado de que setosa es linealmente separable del resto, mientras que versicolor y virginica presentan cierto solapamiento en sus medidas de pétalo.

5. Discusión de hallazgos

1. Atributos relevantes:

J48 seleccionó automáticamente petalwidth y petallength como los únicos atributos necesarios para construir un árbol compacto y preciso, descartando por completo sepalwidth y sepalwidth. Esto demuestra la capacidad de los árboles de decisión para realizar una selección implícita de características.

2. Simplicidad del modelo:

Con solo 5 hojas y 9 nodos en total, el árbol es muy compacto, lo que favorece su interpretabilidad sin sacrificar precisión. Un árbol pequeño como este es fácil de explicar: basta con dos medidas del pétalo para clasificar correctamente el 96 % de las flores.

3. Fuente de error concentrada:

Los errores del modelo se concentran exclusivamente en la frontera entre Iris-versicolor e Iris-virginica, las dos especies cuyos rangos de petalwidth y petallength se solapan parcialmente (por ejemplo, ambas pueden tener anchos de pétalo cercanos a 1.5-1.7 cm). Iris-setosa, en cambio, es perfectamente separable del resto con una sola regla de decisión.

4. Efecto de la poda:

Con un factor de confianza de 0.25 y un mínimo de 2 instancias por hoja, el algoritmo logró un buen equilibrio entre complejidad del árbol y capacidad de generalización, evitando el sobreajuste (overfitting) sin perder precisión relevante.

6. Conclusiones

- El algoritmo J48 aplicado al conjunto de datos Iris produce un árbol de decisión simple (5 hojas, 9 nodos) y altamente preciso (96 % de exactitud, Kappa = 0.94).
- Las medidas del pétalo (petalwidth y petallength) resultan ser los atributos más informativos para distinguir entre las tres especies, mientras que las medidas del sépalo no aportan valor discriminante adicional según el criterio de ganancia de información utilizado por J48.
- Iris-setosa se clasifica de forma prácticamente perfecta, mientras que la totalidad de los errores del modelo ocurre en la distinción entre Iris-versicolor e Iris-virginica, especies que presentan cierto grado de solapamiento en sus atributos morfológicos.
- Estos resultados confirman a J48 como un algoritmo eficiente y fácilmente interpretable para problemas de clasificación multiclase con atributos numéricos como el del conjunto de datos Iris.